

DocClassifier v2.1 기술 개요서

작성 : 정보시스템팀 문서플랫폼파트

문서 등급 : 사내 공유

최종 수정 : 2026년 7월 14일

1. 배경

사내에서 하루에 생성되는 업무 문서는 약 8,200건이며, 이 중 62%가 담당 부서 지정 없이 공용 저장소에 업로드된다. 담당자가 문서를 열어 내용을 확인하고 분류하는 데 건당 평균 3분 20초가 소요되며, 이 작업만으로 월 약 340시간의 인력이 소모된다.

DocClassifier는 업로드된 문서를 자동으로 읽고 사전 정의된 24개 업무 카테고리 중 하나로 분류해 담당 부서 큐로 전달하는 시스템이다. v1.0은 2025년 11월에 배포되었고, v2.1은 분류 정확도와 처리량을 개선한 후속 버전이다.

2. 시스템 구성

DocClassifier v2.1은 세 단계로 동작한다.

- 추출 단계 : 업로드된 파일에서 텍스트를 추출한다. PDF, DOCX, TXT, HWP 네 가지 형식을 지원한다. 텍스트 레이어가 없는 스캔 이미지 PDF는 OCR 전처리 모듈로 우회한다.
- 표현 단계 : 추출한 텍스트를 임베딩(embedding, 문장을 숫자 벡터로 바꾼 표현)으로 변환한다. 문서 전체가 아니라 앞부분 2,000자만 사용한다. 실험 결과 2,000자를 넘겨도 정확도 개선폭이 0.4%p 미만이었기 때문이다.
- 판정 단계 : 임베딩 기반 분류기와 규칙 기반 분류기를 함께 사용하는 앙상블(ensemble, 여러 모델의 판단을 합쳐 결론을 내는 방식) 구조다. 두 분류기의 판단이 엇갈리면 규칙 기반 결과를 우선한다.

3. 성능

사내 테스트셋 12,400건을 기준으로 측정한 v2.1의 성능은 다음과 같다.

- 분류 정확도 : 94.2% (v1.0은 87.6%)
- 매크로 F1 점수 : 0.91
- 평균 응답 시간 : 210ms
- 최대 처리량 : 초당 45건

F1 점수는 정밀도와 재현율의 조화평균으로, 특정 카테고리의 문서 수가 적을 때도 성능을 공정하게 평가하기 위해 사용한다.

정확도 94.2%는 텍스트 레이어가 있는 문서에 한한 수치다. 스캔 이미지 PDF는 OCR 품질에

따라 정확도가 76%까지 떨어지며, 평균 응답 시간도 1.8초로 증가한다.

4. 운영 제약 사항

- 개인정보가 포함된 문서는 마스킹 처리를 거친 뒤에만 분류기에 입력해야 한다. 마스킹 모듈을 거치지 않은 원문을 직접 전달하는 것은 금지되어 있다.
 - 한 번에 3만 건을 초과하는 대량 분류 요청은 실시간 API가 아니라 야간 배치로 분리해야 한다. 실시간 API로 처리할 경우 다른 업무 시스템의 응답 지연을 유발한다.
 - 신규 카테고리를 추가하려면 해당 카테고리 학습 데이터가 최소 200건 이상 필요하다. 200건 미만인 상태로 추가하면 인접 카테고리의 정확도가 함께 하락한다.
 - 분류 신뢰도가 0.6 미만인 문서는 자동 분류하지 않고 담당자 검토 큐로 보낸다.
- 전체 문서의 약 7%가 이 경로로 처리된다.

5. 도입 효과

문서플랫폼파트가 3개 부서를 대상으로 8주간 운영한 결과, 문서 분류에 소요되는 시간이 건당 평균 3분 20초에서 25초로 줄었다. 담당자 검토 큐로 넘어가는 7%를 포함한 수치다.

같은 기간 오분류로 인한 문서 재이관 건수는 주당 평균 41건에서 9건으로 감소했다.

6. 향후 계획

2026년 4분기에 사내 K-Drive와 연동해 전사 확대를 검토하고 있다. 연동 시 업로드 시점에

분류가 완료되므로 별도 업로드 단계가 필요 없어진다. 다만 K-Drive 연동은 정보보호팀의

보안성 검토 승인을 전제로 하며, 승인 일정은 아직 확정되지 않았다.